

ML - модель для прогнозирования эффективности противовирусных соединений

Хакатон - ChemAI: Predict the Cure
май 2026

ДПО Команда № 5 Грузи & Вези



Бизнес-задача и цель проекта


Бизнес-задача:

Разработка лекарств требует значительных временных и финансовых затрат.

ML-модели позволяют заранее оценивать перспективность химических соединений, сокращая количество лабораторных экспериментов и ускоряя поиск эффективных противовирусных препаратов.

Цель:

Разработать модели машинного обучения для прогнозирования ключевых показателей биологической активности и токсичности химических соединений против вируса гриппа - IC50, CC50 и SI - на основе молекулярных дескрипторов.



Данные



1000
соединений



214
числовых
признаков




3
целевые
переменные

train.csv

750 объектов с известными значениями целевых переменных

test.csv



250 объектов, для которых необходимо сделать предсказания




EDA - исследовательский анализ данных

Основные наблюдения:

- Распределения целевых переменных были несбалансированными и содержали экстремальные значения
- Между рядом дескрипторов наблюдалась высокая корреляция
- Признаки имели разные масштабы значений
- Размер датасета требовал контроля переобучения



Pipeline решения



Ключевые шаги предобработки данных:

- ✓ Анализ выбросов и распределений признаков
- ✓ Исследование корреляций между признаками
- ✓ Логарифмирование целевых переменных (IC50, CC50, SI)
- ✓ Заполнение пропусков средним значением
- ✓ Масштабирование признаков для моделей

Feature Engineering:

- ✓ Анализ физико-химических характеристик молекул
- ✓ Создание новых признаков на основе молекулярных дескрипторов
- ✓ Отбор информативных признаков
- ✓ Снижение влияния мультиколлинеарности

AutoGluon Tabular - специализированный модуль библиотеки машинного обучения AutoGluon от Amazon, который полностью автоматизирует создание ML-моделей для работы с табличными данными

Почему мы выбрали AutoGluon?



Автоматический подбор ML-моделей

Сравнение множества алгоритмов и выбор лучших



Ансамблирование

Stacking и Bagging для повышения качества предсказаний



Высокая эффективность

Отличные результаты на табличных данных



Экономия времени

Минимальная ручная настройка и быстрые эксперименты



Воспроизводимый ML-пайплайн

Сохранение моделей и полного пайплайна обучения

Что это дало в нашей задаче?



Быстро протестировали различные алгоритмы машинного обучения



Получили сильный baseline без длительного подбора гиперпараметров



Автоматически сформировали ансамбли моделей для повышения качества предсказаний



Улучшили точность прогнозирования IC50, CC50 и SI



Сосредоточились на анализе данных и улучшении признаков вместо ручной настройки десятков моделей

Лучшие модели и результаты прогнозирования

1. Лучшая модель предсказания pIC50 (IC50)

★ **WeightedEnsemble_L3** score_val* - 0.141988

Веса базовых моделей в ансамбле:

- NeuralNetTorch_r22_BAG_L1: 0.44
- CatBoost_BAG_L2: 0.04
- ExtraTrees_r172_BAG_L1: 0.04
- RandomForest_r127_BAG_L1: 0.20
- LightGBMXT_BAG_L2: 0.28

2. Лучшая модель предсказания pCC500 (CC50)

★ **WeightedEnsemble_L3** score_val* - 0.102673

Веса базовых моделей в ансамбле:

- NeuralNetTorch_r143_BAG_L1: 0.1176
- LightGBMXT_BAG_L2: 0.2941
- ExtraTrees_r172_BAG_L2: 0.5882

3. Лучшая модель предсказания log10_SI (SI)

★ **WeightedEnsemble_L3** score_val* - 0.127299

Веса базовых моделей в ансамбле:

- CatBoost_r137_BAG_L2: 0.0556
- ExtraTrees_r172_BAG_L2: 0.6667
- RandomForest_r127_BAG_L1: 0.2222
- LightGBMXT_BAG_L2: 0.0555

Kaggle Leaderboard

Score = 295,24

*score_val - pinball loss (квантильная функция потерь)

Итоги проекта

Что удалось сделать?

- Проведен полноценный EDA
- Построены ML-модели
- Улучшено качество предсказаний
- Получен результат на Kaggle

Ценность для фармацевтической разработки:

- ✓ Сокращение количества лабораторных экспериментов
- ✓ Ускорение ранних этапов Drug Discovery
- ✓ Снижение времени и стоимости исследования новых соединений
- ✓ Поиск наиболее эффективных и безопасных молекул
- ✓ Data-driven подход к поиску новых лекарств

Наша команда



Алла Мишра
team leader



Ирина Рыжова



Михаил Комаров



Евгений Погожев



Гульназ Мусина



Документация проекта

**Спасибо
за внимание!**



ДПО Команда № 5 Грузи & Вези